

# Tópicos Especiais em Computação I

## Redes Neurais


Patrícia Lucas

Bacharelado em Sistemas de Informação  
IFNMG - Campus Salinas

Salinas  
Março 2021

# Referência

## Redes Neurais



## Capítulo 7: Modelos baseados em otimização.

Inteligência Artificial: Uma abordagem de aprendizado de máquina. Katti Faceli...[et al.]. - Rio de Janeiro: LTC, 2011.


# Roteiro

## Redes Neurais

- O neurônio artificial
- Funções de ativação
- Aprendizado supervisionado
- Perceptron
- Adaline
- Perceptron de múltiplas camadas - MLP

# O neurônio artificial


## Redes Neurais



# Funções de ativação

## Redes Neurais

**Função degrau:** usada na camada de saída para problemas de classificação.




$$f(u) = \begin{cases} 1 & \text{se } u \geq 0 \\ 0 & \text{se } u < 0 \end{cases} \quad (1)$$

# Funções de ativação

## Redes Neurais

**Função linear:** usada na camada de saída para problemas de regressão.




$$f(u) = u \quad (2)$$

Intervalo:  $[-\infty, +\infty]$

# Funções de ativação

## Redes Neurais

**Função sigmóide:** usada na camada de saída para problemas de classificação binária.




$$f(u) = \frac{1}{1 + e^{-u}} \quad (3)$$

Intervalo:  $[0, 1]$

# Funções de ativação

## Redes Neurais

**Função softmax:** usada na camada de saída para problemas de classificação multiclasse.



$$f(u) = \frac{e^{u_i}}{\sum e^{u_i}} \quad (4)$$


Intervalo:  $[0, 1]$



# Funções de ativação

## Redes Neurais

**Função tangente hiperbólica:** usada na camada escondida.




$$f(u) = \frac{e^u - e^{-u}}{e^u + e^{-u}} \quad (5)$$

Intervalo:  $[-1, 1]$

# Funções de ativação

## Redes Neurais

**Função Relu (unidade linear retificada):** usada na camada escondida.



$$f(u) = \max(0, u) \quad (6)$$

$$f(u) = \begin{cases} 0 & \text{se } u < 0 \\ u & \text{se } u \geq 0 \end{cases}$$

# Aprendizado supervisionado

## Redes Neurais

Nesse tipo de aprendizado, os pesos são ajustados através da comparação da saída da rede com a saída desejada.

O método mais comum de aprendizado supervisionado é o aprendizado por correção de erros, em que procura-se minimizar o erro da resposta atual da rede em relação à saída desejada.

O erro:

$$e = y - \hat{y} \quad (7)$$

# Aprendizado supervisionado

## Redes Neurais

Para a atualização dos pesos por correção dos erros usa-se a equação 8, chamada de Regra Delta:

$$w_i(t + 1) = w_i(t) + \eta ex_i \quad (8)$$


onde:

- $w_i(t + 1)$  = novos pesos
- $w_i(t)$  = pesos atuais
- $\eta$  = taxa de aprendizagem
- $e$  = erro
- $x_i$  = entradas

# Perceptron

## Redes Neurais

O perceptron é uma rede neural de camada única que resolve problemas de classificação linear (binária).



# O algoritmo Perceptron


## Redes Neurais

1. Inicializar  $\eta$
2. Inicializar os pesos  $w$  com valores aleatórios
3. Repita até  $\sum e^2 = 0$ 
  - 3.1 Calcule  $f(u)$
  - 3.2 Calcule  $e$
  - 3.3 Aplique a regra de atualização dos pesos para todos os pares  $(x_i, y_i)$  do conjunto de treinamento
  - 3.4 Calcule  $\sum e^2$

# Algumas considerações...

## Redes Neurais


- Valor da taxa de aprendizado ( $\eta$ ): valores muito pequenos podem levar a um tempo de convergência muito alto, enquanto que valores muito altos podem levar a instabilidade no treinamento.
- Inicialização dos pesos: em geral devem ser inicializados com valores no intervalo  $[-0.5, 0.5]$ .
- Normalizar e embaralhar as entradas.



# Adaline

## Redes Neurais

O adaline é uma rede neural de camada única que resolve problemas de regressão.






# Perceptron de múltiplas camadas - MLP

## Redes Neurais

- As redes vista até aqui, com uma única camada, têm a limitação de resolver apenas problemas com características lineares.



- No entanto, a não-linearidade é inerente à maioria das situações e problemas reais, sendo necessária a utilização de estruturas com características não-lineares para resolução de problemas de maior complexidade.
- As não-linearidades são incorporadas a modelos neurais através das funções de ativação (não-lineares) de cada neurônio da rede e da composição da sua estrutura em camadas sucessivas.

# Perceptron de múltiplas camadas - MLP


## Redes Neurais

**Arquitetura:** o comportamento de uma MLP com 1 camada intermediária, pode ser descrito por meio de duas transformações sucessivas:

$$Y(H(x, w_i), w_s) \quad (9)$$

onde:


- $w_i$  são os pesos da camada intermediária.
- $w_s$  são os pesos da camada de saída.



# Perceptron de múltiplas camadas - MLP

Redes Neurais

**Número de camadas:**



# Perceptron de múltiplas camadas - MLP

## Redes Neurais

### Número de neurônios:

- O número de neurônios determina a capacidade da rede em resolver problemas de determinada complexidade.
- Quanto maior o número de neurônios, maior a complexidade da rede e maior a sua abrangência em termos de soluções possíveis.
- A determinação do número de neurônios é o problema mais fundamental em aprendizado de redes neurais, mas ainda não existe uma regra geral para resolvê-lo.

# Perceptron de múltiplas camadas - MLP

## Redes Neurais

O treinamento de redes de uma única camada por meio do aprendizado supervisionado e correção de erros é realizado através da equação:

$$w_i(t + 1) = w_i(t) + \eta ex_i \quad (10)$$

$$e = y - \hat{y} \quad (11)$$

No entanto, para redes de múltiplas camadas esse procedimento pode ser aplicado somente na camada de saída, já que não existem saídas desejadas nas camadas intermediárias!

# Perceptron de múltiplas camadas - MLP

## Redes Neurais

**Solução:** algoritmo de retropropagação de erros (back-propagation).

- O princípio desse algoritmo é, utilizando-se do gradiente descendente, estimar o erro das camadas intermediárias por meio de uma estimativa do efeito que estas causam no erro da camada de saída.
- Assim, o erro de saída da rede é calculado e este é retroalimentado para as camadas intermediárias, possibilitando o ajuste dos pesos proporcionalmente aos valores das conexões entre as camadas.
- Requer o uso de funções de ativação contínuas e diferenciáveis.