

# Tópicos Especiais em Computação I

## Regressão Linear


Patrícia Lucas

Bacharelado em Sistemas de Informação  
IFNMG - Campus Salinas

Salinas  
Março 2021

# Referência

## Regressão Linear



### Capítulo 3: Linear Regression

An Introduction to Statistical Learning: with Applications in R. G. James, D. Witten, T. Hastie, and R. Tibshirani. Springer, 2013.

# Regressão linear simples

## Regressão Linear

É uma abordagem linear muito simples para prever uma resposta quantitativa  $Y$  com base em uma única variável preditora  $X$ .

Supõe-se que exista aproximadamente uma relação linear entre  $X$  e  $Y$ .

$$Y \approx \beta_0 + \beta_1 X \quad (1)$$

$\beta_0$  e  $\beta_1$  são duas constantes desconhecidas que representam os termos de interceptação e inclinação no modelo linear.


Juntos,  $\beta_0$  e  $\beta_1$  são conhecidos como coeficientes ou parâmetros do modelo.

# Regressão linear simples

## Regressão Linear

Exemplo:

$$Sales \approx \beta_0 + \beta_1 TV \quad (2)$$



# Regressão linear simples

## Regressão Linear

Na prática,  $\beta_0$  e  $\beta_1$  são desconhecidos. Portanto, antes de podermos usar o modelo para fazer previsões, precisamos usar dados para estimar os coeficientes.

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$


Onde  $x$  são os atributos preditores (entradas) e  $y$  o atributo alvo (saídas).

Nosso objetivo é obter estimativas dos coeficientes  $\beta_0$  e  $\beta_1$  de modo que o modelo linear se ajuste bem aos dados disponíveis.

# Regressão linear simples

## Regressão Linear

Em outras palavras, queremos encontrar uma reta cuja interceptação  $\beta_0$  e inclinação  $\beta_1$ , de modo que a linha resultante seja o mais próxima possível dos  $n$  pontos de dados.



# Regressão linear simples

## Regressão Linear

Existem várias maneiras de medir a proximidade, usaremos o **Método dos Mínimos Quadrados**:

Seja  $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$  a previsão para  $Y$  com base no  $i$ -ésimo valor de  $X$ .

Então  $e_i = y_i - \hat{y}_i$  representa o  $i$ -ésimo erro, ou seja, a diferença entre o  $i$ -ésimo valor de resposta observado e o  $i$ -ésimo valor de resposta previsto pelo modelo linear.

Definimos a soma dos erros quadráticos (SEQ) como:

$$SQE = e_1^2 + e_2^2 + \dots + e_n^2 \quad (3)$$

ou equivalente:

$$SQE = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2 \quad (4)$$

# Regressão linear simples

## Regressão Linear

A abordagem dos mínimos quadrados escolhe  $\hat{\beta}_0$  e  $\hat{\beta}_1$  para minimizar a SEQ. Usando alguns cálculos, pode-se mostrar que os minimizadores são:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \hat{x})(y_i - \hat{y})}{\sum_{i=1}^n (x_i - \hat{x})^2} \quad (5)$$

$$\hat{\beta}_0 = \hat{y} - \hat{\beta}_1 \hat{x} \quad (6)$$

onde  $\hat{y}$  e  $\hat{x}$  são as médias da amostra:

$$\hat{y} = \frac{1}{n} \sum_{i=1}^n y_i \quad (7)$$

$$\hat{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (8)$$



# Regressão linear simples

## Regressão Linear

Ajuste da regressão linear simples para os dados de Publicidade usando vendas como resposta e TV como preditor, onde  $\hat{\beta}_0 = 7,03$  e  $\hat{\beta}_1 = 0,0475$ .

